组会汇报 • 2026-09-16 ~ 09-17

Agent Hallucination：检测器底座与自进化框架

先修尺子，再长手。

修掉 13 项污染结论的缺陷 · 校准评估读数 · 把自进化框架重构成可核验的 H_t 基座

框架改动不改任何门限与准入规则；真实收益尚未在任何真实运行中体现

结论先行

本周三条主线，对应“修底座 → 校准尺子 → 重构框架”

1 修底座 —— 13 项缺陷修复

mini 留出评估必然崩溃、DSL 零命中可机械定罪、辩护投票取首票且 quorum 无下限、冻结听证永不命中、下游故障被洗成 authoritative 终态。全部配套回归测试。

2 校准尺子 —— 让评估能读出改进

gain 集补齐极性下限，两种 claim 方向都可计分；巡检对准已部署版本并保留裸底座对照，把新引入退化、常驻残余、已修复分离为可读字段。

3 重构框架 —— H_t = (G, C, T, M, R) 基座

可装载、双层哈希可核验的五组件清单，叠加覆盖可读数、终态区分、记忆接入、覆盖响应策略与断点续跑。

边界：以上都是结构与设施改动，不改变任何门槛值、语义法则或准入规则；真实收益是否成立，只能由重跑真实实验回答。

真实实验：第 1 轮闭环，准入 0

首次用真实 GLM-5.3-flash 跑通 LLM proposer → detector 配对评估 → 四门准入（开发 30+10 协议）

1

个稳定失败族

2 例同机制，诊断完整

3

个合法候选

结构门与无害门全部通过

0

真实准入

行为门/边际门全部拒绝

第 2 轮

被中断未完成

无 gate 结果

- **门限未放宽，0 准入是门限拒绝的结果**

  两个候选在 sentinel 上各出现一次局部改善，但没有候选满足行为方向与 gain 收益要求 → 不是“没有产出候选”，是候选没过门。

- **缺陷注入审计通过，账本有效**

  2/2 故意注入的缺陷候选被正确拒绝（结构门拦下泄漏案例 ID 的候选）；verify-ledger valid，12 条记录，哈希链完整。

证据边界： “收益未成立”只对本次轮次成立；第 2 轮未完成，不能据此推断框架在真实数据上永无收益。

三个候选为何全部被拒

行为门看“行为是否与声明一致”，边际门看“配对评估是否净增正确案例”

IV-1-001	recall_trigger：把“有交付结果但工具输出为 None”的 judge 负例送进召回网	**行为门**	声称会触发召回，实测 recall_triggered_cases = 0，行为与声明不符
IV-1-002	recall_trigger：把“交付结果无成功工具观测锚定”的 judge 负例送进召回网	**边际门**	行为门通过，sentinel 上确实修好 1 例漏报，但 gain 集净增为 0（marginal_cases = 0 < 1）
IV-1-003	text_boundary：让因果升级复核未锚定/失败的交付	**行为门**	声明要提升召回，实测无 TP 增益，而是在 sentinel 移除了 1 个 FP，方向不符

关键在 IV-1-002：真的做出了有效修改，读数为 0

它通过了行为门、真实触发一次、并在 sentinel 修好 1 个漏报，却被边际门以 marginal_cases = 0 < 1 拒绝 —— 原因是 gain 集 G 里根本没有 FN，召回类候选无处得分。这把问题从“门太严”指向了“尺子读不出”。

复核更正：patrol 口径与 gain 集构成

深度复核后，早期记录的混淆矩阵与根因归因都需要更正

patrol（裸底座，20 例）标准口径

12	4	1	3
正确	FN 漏报	FP 误报	U 未决

早期记录的“5 FN、3 FP”把 3 个未决/降级案例按 gold 方向混入了错误统计，不能作为标准混淆矩阵使用。

失败族与逐候选实测

1 个稳定失败族（BFCL/017、OpenDeepSearch/086 两例同机制）

IV-1-002 在 sentinel 修好 1 例 FN；**IV-1-003** 修好 1 例 FP；两者在 G 上都未形成收益。

gain 集 G 的构成

2 TP • 1 TN • 1 FP • 0 FN

G 里没有 FN，而 marginal_cases 只统计全对案例的净增 —— 召回类候选在这里天然无法计分。

引擎其实已算出该极性机会为 0，

但这个信号只写进反馈，不改变本轮结论。

真实服务与数据完整性

当前配置 GLM-5.3-flash，合成两例与真实数据集小规模路径检查

6/6

真实数据集终态一致

6 例 × 2 次重复，0 unresolved

12/12

authoritative

判定终态均为权威结果

695

原始文件 SHA-256 一致

693 个案例，未改动

本周较弱的一环：定位

判定 6/6 一致，但含定位步的一致性仅 5/6，正例定位命中约 1/6。召回升级分支已用单票强制触发证明路径连通，但该条件改变了判定，正常配置下的触发率与真实增益仍未验证，需要单独度量。

不能宣称的：合成两例与 6 例开发复测都不代表复杂 Agent 轨迹的准确率或泛化；案例已被开发使用，默认没有干净的独立终审集。

代码 Review：13 项缺陷修复

全部配套回归测试；测试 220 → 244 passed，scripts/verify.py 七项校验全 PASS

01	**mini 留出评估必然崩溃**	gold 未补齐，唯一样本外读数整体失效
02	**DSL 可用零命中触发机械定罪**	无证据也能判成幻觉，污染所有下游结论
03	**辩护投票取首票、quorum 无下限**	同一票集可能得到相反终态；单票即成多数
04	**冻结听证永不命中**	比较未投影字段，所谓“冻结”实为实时重跑
05	**下游故障被洗成 authoritative**	模型错误与服务故障无法区分，错误终态被当成权威

中等项 8 项：registry 哈希可缺省、judge basis 类型可中断整批、upgrade.pre 钩子双执行、guard 资格探测带副作用、boundary 极性空约束、无害门默认只保护 2 例、缺陷审计可空过、正式路径无法续跑。

评估侧优化：让尺子能读出改进

真实第 1 轮暴露的前置问题不是“手不够”，而是“做出了有效修改却读数为 0”

① 边际集 G 加极性下限

在来源配额之上保证每极性最少案例数（开发各 1，正式 max(1, n//4)），使两种 claim 方向都可被计分；下限不可满足时直接报错，而不是静默弱化。

split_manifest_report 新增 gain_polarity / sentinel_polarity，使构成可读。

> 这是必要不充分条件：G 里有该极性案例 ≠ 该案例是修复机会。

② 巡检对准已部署版本，保留裸底座对照

新增配置 patrol_registry：巡检臂测已部署版本（H_t），参照臂测裸底座。registry 为空时两臂是同一次评估，冷启动成本不变；部署后才多出第二次 sweep。保留裸底座是必需的 —— 没有参照，三类失败都无法计算。

巡检双臂把失败分成三类

- **new_failures**
  准入引入的退化
- **persisting_failures**
  常驻残余（裸底座也错）
- **resolved_by_active**
  已被活跃干预修复

原 VaG 保证从“断言”变为可核对数据；冷启动时两臂相同，不增加成本。

框架重构：H_t = (G, C, T, M, R) 基座

把此前只存在于文档里的“一代系统”做成可装载、双层哈希可核验的载体 —— 结构改动，不动门槛值

G
评估集

阶段入口逐个导入

失败即构建失败

C
上下文预算

视图预算与渲染器

从 packet 实测读取

T
活跃干预

来自活跃 registry

M
经验存储

三类经验

有界检索

R
策略配置

来自配置

配置变化只使 R 变

组件由代码推导，不是手写描述；装载时重新推导摘要 —— 被编辑过的清单会被发现。

在其上叠加三项能力（仍不改门限）

覆盖可读数 cycle 报告新增 instrument 块，按轮报告每极性可修复案例数与不可测量极性

终态可辨 admitted / rejected / not_evaluated / unresolved ——“未测量”不再等于“已证伪”

记忆接入草拟 已准入程序性经验与开放缺口进入 proposer 提示，账本可核对“系统用上了自己的经验”

边界： 记忆“被供给”≠“改善了草拟质量”，后者需带/不带记忆的对照实验；新增 harness.py / gaps.py / memory.py / contracts.py。

覆盖响应与断点续跑

两项让框架“产生动作、可恢复”的改动；测试 308 → 312 passed

覆盖响应 coverage_response

strict（默认）	not_evaluated · 无响应，行为逐字同改动前
replacement	admitted · 换替代集后确实修好了案例
replacement_or_skip	skipped_unmeasured · 无匹配集则跳过

三种模式在同一合成场景下得到三种不同终态 —— 替代集能够改变准入结果，因此默认关闭、按方向开启，并把动作写入 instrument.coverage_responses。

边界：替代集目前只驻内存，尚未持久化、也未用于真实实验；持久化需与主 gain 集同等的 gold/协议/暴露保证。

断点续跑：第 2 轮作废的根因

根因不是“中断”，是契约设计

检查点指纹包含 registry 哈希，而该轮已提交自己的准入 → 哈希改变 → 续跑永远拒绝

修复：契约记录本轮起始 registry

续跑发现 live registry 已含本轮准入时，先回退到起始状态再评估，避免门控拿候选与自己比较

回退动作写入账本

resume_registry_restored，快照链保留，那次准入仍可恢复；同一轮只产生一次 admitted 与一次 registry_written

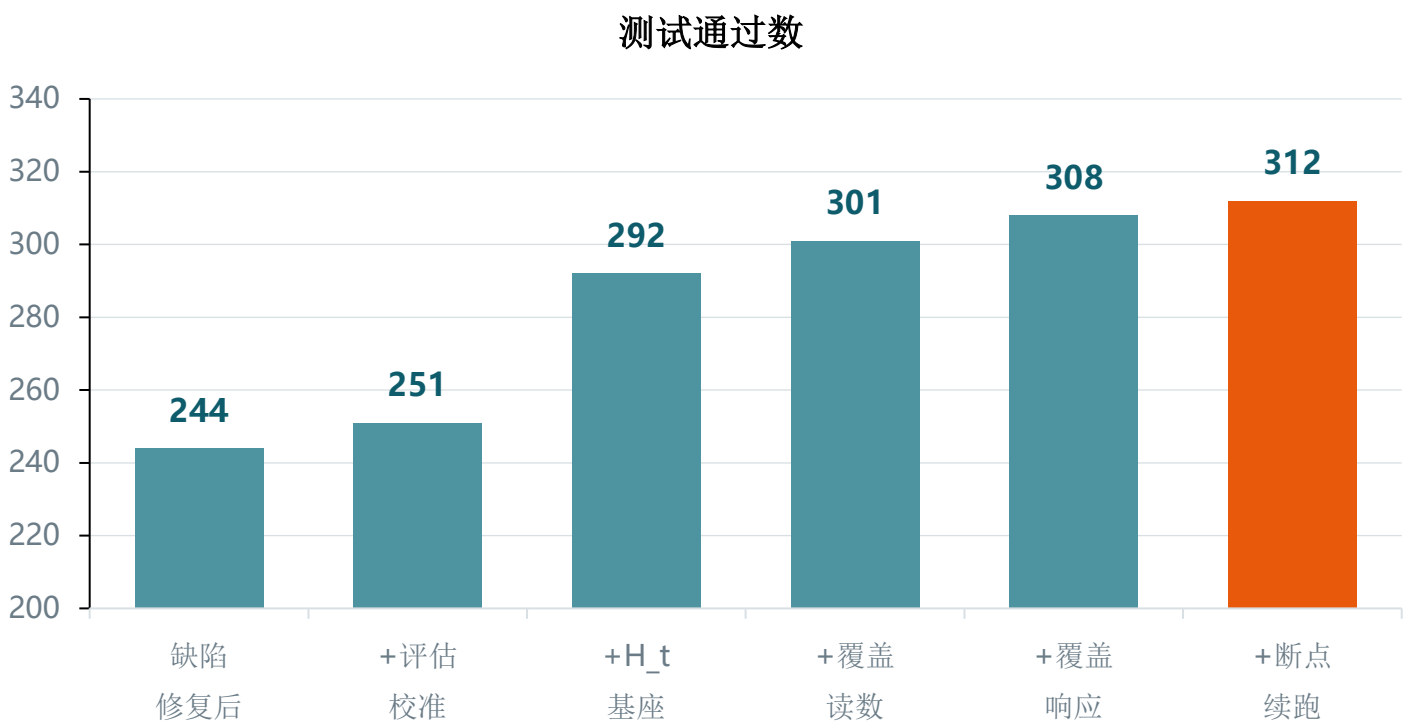
实测

“准入已提交、写报告前中断”场景修复前永久失败，修复后同一账本续跑成功且不重复准入

诚实边界：提案未落盘就中断仍拒绝重抽（等于在同一批已固定案例上追加搜索），错误信息会指向换新 work_root。

关键数字

测试规模的增长：220 → 244 → 251 → 292 → 301 → 308 → 312 passed，全部 0 failed / 0 skipped



九项

离线验证全 PASS · scripts/verify.py

13 项

缺陷修复，全部配回归测试

0

真实准入（第 1 轮，门限未放宽）

6/6

真实路径终态一致（6 例 × 2 次）

下一步

框架层已全部就位，但这些改动尚未在任何真实运行中发挥作用

最高优先级

用现有 30+10 开发协议重跑真实两轮进化

重跑是唯一能判断新框架价值的方法；不放宽门限换取准入。

1	**先做小规模配对诊断**	验证原失败族的召回触发、听证可达性与指控一致性，再冻结新协议
2	**冻结新的评估协议**	必须具备目标错误机会并按机制/极性分层，保留独立验证集
3	**消融证明机制贡献**	裸底座 / 固定干预 / 完整进化，覆盖带不带记忆、开不开覆盖响应
4	**最小 improver**	读源码、局部执行、形成可装载改动 —— 前置条件已完成，排最后

先修尺子，再长手。

框架已就位，真实收益待重跑验证。

这一周没有产生“正收益”的结论，但把“为什么测不出收益”变成了可核对的事实。

欢迎讨论：评估协议的设计与下一步的优先级。