海市蜃楼 - B恩奇：LLM A先生正在产生幻觉，且H在此处W以F寻找T他们。

匿名作者
经过双盲评审的论文

摘要

幻觉对基于大型语言模型（LLM）的智能体构成重大风险，通常表现为由于认知环境中虚构或误解的信息所引发的幻觉行为。尽管近期研究已揭示此类故障现象，但现有的评估方法仍存在碎片化问题且缺乏系统化的测试框架。本文提出**mirage-Bench——M**化**I**幻觉在**R** isky **AGE** nt场景中的首个统一基准，用于在交互式LLM-智能体场景中诱发和评估幻觉现象。我们首先建立了一个包含三个维度的分类体系来界定智能体幻觉：即与(i)任务指令、（ii）执行历史或（iii）环境观测结果不符的行为；为进行分析，我们首先通过对现有智能体基准进行系统性审查来诱发此类故障，随后采用快照策略以确定性和可重复的方式隔离决策节点并合成测试案例。为评估幻觉行为，我们采用细粒度层级的“大语言模型作为评判者”范式，并结合定制化的风险感知提示，从而能够在无需枚举全部动作空间的情况下，对智能体行为进行可扩展且高保真的评估。mirage-B Ench针对大语言模型智能体的失效模式提供了具有实践价值的见解，为在交互环境中有效缓解幻觉现象奠定了理论基础。

1 我的介绍

大型语言模型（LLM）的快速发展与规模化应用催生了智能代理系统，这些系统以LLM作为认知核心来感知环境、自主决策，并在网页自动化（Zhou 等人，2023；Drouin 等人，2024）、软件工程（Jimenez 等人，2023）及具身机器人学（Shridhar 等人，2020）等多个领域与外部系统进行动态交互。尽管展现出显著的通用性，基于LLM的智能体仍因其底层神经架构存在一个关键局限——幻觉现象，即生成与输入上下文不一致的输出（Ji 等人，2023）。与传统自然语言生成（NLG）任务不同，智能体中的幻觉现象会直接导致不良行为，因模型自主性和人工监督不足而加剧现实风险。

幻觉现象已在多种智能体基准测试中被观察到。在TheAgentCompany研究中（Xu 等人，2024b），一个显著案例是智能体因产生幻觉性的上下文切换而无意间泄露用户的敏感凭证；而在Swe-Bench的另一案例中（Jimenez 等人，2023；Yang 等人，2024），智能体为强制修复漏洞而添加了不存在的软件包。尽管这类情况在智能体研究中已有报道，但仍较为零散。缺乏统一的测试案例集来深入理解幻觉现象发生的时间与原因，使得制定可靠的缓解策略或建立基准评估体系变得愈发困难。本研究旨在填补这一关键空白。

在交互式智能体环境中评估幻觉现象，相较于传统基准方法（这些方法通常聚焦于单轮问答场景，如TruthfulQA（Lin等人，2021）或HaloGEN（Ravichander等人，2025）），面临着独特的方法论挑战。首先，智能体的输出无法直接通过FACTScore（Min等人，2023）等外部事实性评分工具进行验证；判断某个动作是否属于幻觉行为高度依赖于具体情境，这使得验证过程更为复杂。其次，智能体运行于多种环境：基于网络的界面（Yao等人，2022；Zhou等人，2023；Drouin等人，2024；Lu等人，2024；Xu等人，2024b）、操作系统（Xie等人，2024；Wu等人，2024b）或Android应用程序（Rawles等人，2024；Bai等人，2024）。这些设置使得统一评估框架的设计变得复杂（Yehudai 等人，2025）。

最后，分支决策的随机性使得代理行为的确定性降低，且难以可靠地复现。

为应对这些挑战，我们提出了一种统一的基准评估框架mirage-B Ench，该框架能够在交互式大语言模型-智能体场景中对幻觉现象进行*分类*、*提取*和*评估*：

· 为进行*分类*，我们基于先前将幻觉区分为与上下文不一致与与事实知识不一致的研究（Ji 等人，2023；Huang 等人，2025；Tonmoy 等人，2024），进一步拓展了这一分类框架。针对智能体应用场景，我们将该分类体系精炼为三类：a）**违背任务指令**——智能体执行违反任务目标、超出约束条件或依赖未明确用户意图的动作；b）**违背交互历史**——智能体重复已完成步骤、忽略先前结果或以其他方式违背自身的动作-观察轨迹；c）**违背环境观测**——智能体产生不存在于环境中的元素或属性幻觉，例如点击不存在的按钮或假设未达到的状态。

·为*诱发*幻觉现象，我们对现有的智能体基准测试数据进行了全面审查（Zhou 等人，2023；Xie 等人，2024；Drouin 等人，2024；Xu 等人，2024b；Jimenez 等人，2023；Yao 等人，2024），以识别*易引发幻觉的风险场景*。这些风险场景经过进一步分类后被用于构建新的测试场景，从而实现更广泛且系统化的覆盖。由于交互轨迹常呈现随机分支特性，难以可靠地复现幻觉行为。为此，我们采用**情境快照策略**：在每个测试案例中，将智能体状态冻结于潜在幻觉发生点前的时刻，随后引导大语言模型在受控的确定性情境中生成下一步动作。

· 为*评估*幻觉现象，我们采用细粒度层面的*LLM作为评判者*范式（Gu 等人，2024；Zhuge 等人，2024），设计针对特定风险情境的提示指令，引导独立的评判模型从语义层面将候选行为背后的动机与意图与周围情境要素相联系，并据此评估其忠实度。该方法能够在保持对智能体幻觉细微差别的准确性的前提下实现可扩展的评估。

据我们所知，mirage-B Ench是首个为研究交互式大语言模型智能体中的幻觉现象提供系统化方法的框架。本文的主要贡献如下：

1. 提出一种基于对任务指令、交互历史及环境观察的不一致性特征，对能动性幻觉进行分类的**统一分类体系**。
2. 我们提出一种**基于快照的提取策略**，该策略能在**现实风险场景下**冻结智能体的状态，从而在受控环境中可靠地复现并评估幻觉现象。
3. 发布一套**基准测试与评估工具包**，其中包含可扩展的“大语言模型作为评判者”框架，用于实现对动作忠实性的高保真、领域通用验证。
4. 我们的研究提供了**实证依据**，有力挑战了普遍认知：即使在最先进的模型中，幻觉现象依然存在，且专有智能体与开源智能体之间的差距出乎意料地微小。归因分析表明，这种不稳定性源于训练数据对“成功操作流程”的偏重——导致智能体忽视关键的失败反馈，凸显了开展多样化风险场景训练的迫切必要性。

2 相关工作

通用大语言模型智能体基准测试。目前已有多种基准测试方法用于评估基于大语言模型（LLM）的智能体在复杂环境中将高级指令转化为可执行动作的能力。早期的研究如Mind2Web（Deng 等人，2023）依赖静态用户交互记录，难以捕捉动态行为；相比之下，WebArena、WorkArena和OSWorld（Zhou 等人，2023；Drouin 等人，2024；Xie 等人，2024）则引入了动态自托管环境，通过环境状态分析实现稳健的端到端评估。在扩展交互目标与环境范围方面，TheAgentCompany（Xu等人，2024b）与τ-Bench（Yao 等人，2024）评估智能体在类工作场景中与模拟人类交互的能力，而Swe-Bench（Jimenez等人，2023）将智能体置于软件工程工作流程中，测试其在导航和修改真实代码仓库方面的能力。更广泛的评估框架如AgentBench（Liu 等人，2023）和BrowserGym（Chezelles 等人，2024）则提供了跨多个领域的系统化、统一性评估。由于这些基准测试主要关注大语言模型智能体能完成的任务，mirage-B Ench则将视角转向更精细的层面——评估智能体所采取行动的忠实度，以及由引发非忠实决策的各种场景所暴露的真实风险。总之，与之相比

	Agentic 场景？	多轮次 交互场景？	多个：多种 代理环境？	没有 Env 。 设置？	现实世界 风险触发因素？	幻觉 验证器？
H ALU E VAL-2.0（LI等，2024A）	✗	✗	-	-	✗	✓
H ALO基因（Ravichander等人，2025）	✗	✗	-	-	✓	✓
E NV D干扰（MA等，2024）	✓	✗	-	-	✓	✓
W EB A 任娜（周等人，2023）	✓	✓	✗	✗	✓	✗
T HE A GENT C OMPANY (许等，2024B）	✓	✓	✗	✗	✗	✗
一位 资深 专家（刘等人，2023）	✓	✓	✓	✗	✗	✗
Mirage-B Ench（**我们的**）	✓	✓	✓	✓	✓	✓

表1：现有研究中评估大语言模型在幻觉生成与智能行为能力方面的比较。各列代表以下评估标准：是否要求大语言模型在外部世界执行动作（智能设定场景）；交互情境是否处于多轮动态环境中（多轮交互情境）；任务领域是否涉及多个交互环境（多智能体环境）；实验设置是否避免复杂环境配置（无环境设置）；情境是否包含现实世界中常见的真实风险触发因素（现实风险触发因素）；以及是否支持无需人工标注即可自动、可扩展地验证异常行为（可扩展幻觉验证器）。

与表1中的现有基准相比，mirage-B Ench通过基于真实环境的逼真交互情境，填补了在研究大型语言模型（LLM）智能体幻觉现象方面的关键空白；关于*LLM中的幻觉现象及LLM智能体的风险*的进一步讨论详见附录A。

3 E扩展型C分类法在LLM工具中对H幻觉的分析

将幻觉概念从 NLG 扩展到LLM智能体。“*幻觉*”这一术语最初出现在自然语言生成（NLG）领域（Bang 等人，2025；Huang 等人，2025；Ji 等人，2023），指输出结果偏离事实准确性或输入内容的真实度。先前研究主要区分两种类型：**外源性幻觉**（内容与外部可验证信息不符）和**内源性幻觉**（内容与上下文输入相矛盾）。将这一概念应用于LLM智能体会带来新的挑战：与具有静态输入-输出映射关系的传统 NLG 任务不同，智能体采用更复杂的认知架构（Sumers 等人，2023），整合了规划模块、记忆缓冲区、环境感知及反馈回路等组件；部分智能体还具备学习与自我进化机制，使得幻觉来源的判定更为困难。

基于通用ReAct框架对幻觉行为进行分类。为便于讨论，我们重点研究基于ReAct框架（Yao 等人，2023）构建的通用智能体：该框架中的基础语言模型通过分析三类上下文输入（任务指令、当前环境观测数据以及智能体历史交互记录）来生成每一步的动作。在此框架下，当智能体产生的动作与上述任一组成部分不符时，即构成幻觉行为。这包括：a) 违反或伪造任务目标——例如调用不存在的API或将用户意图超出给定指令范围进行推断（**任务指令不忠实性**）；b) 与先前操作及反馈相矛盾或忽视这些信息——例如重复已完成步骤或忽略观察到的失败情况（**交互历史不忠实性**）；c) 错误解读当前环境状态——例如点击不存在的按钮、假设从未发生过的转换已完成，或错误感知某些界面元素的存在（**环境观测不忠实性**）。

幻觉行为与错误行为之间的本质差异。幻觉行为与普通错误的区别在于：前者源于智能体所接收情境信息中存在误判或虚构要素，而非由领域知识不足、规划缺陷或历史信息缺失等局限性所致。尽管两者在实际操作中可能存在重叠，但严格遵循输入信息有助于智能体从次优决策或探索性尝试中恢复；而幻觉行为则会促使智能体在无意识状态下采取偏离常规的行为，从而在现实应用中导致更严重的后果。此外，针对错误行为的常见修正措施（如训练后调整或知识注入）往往无法提升与实时输入信息的一致性，甚至可能因过度依赖先验假设而非基于实际情境来制定行为方案，反而加剧幻觉现象。

4 幻象：B 通过 E 融合的 R ISK S 设置及 LLM 作为 J UDGE，对 LLM A 中的所有 H 幻觉进行标记

建立能够诱发大型语言模型（LLM）智能体产生幻觉案例的基准测试方法存在以下挑战：1）幻觉现象往往难以预测，且在不同运行次数和不同模型间表现各异；

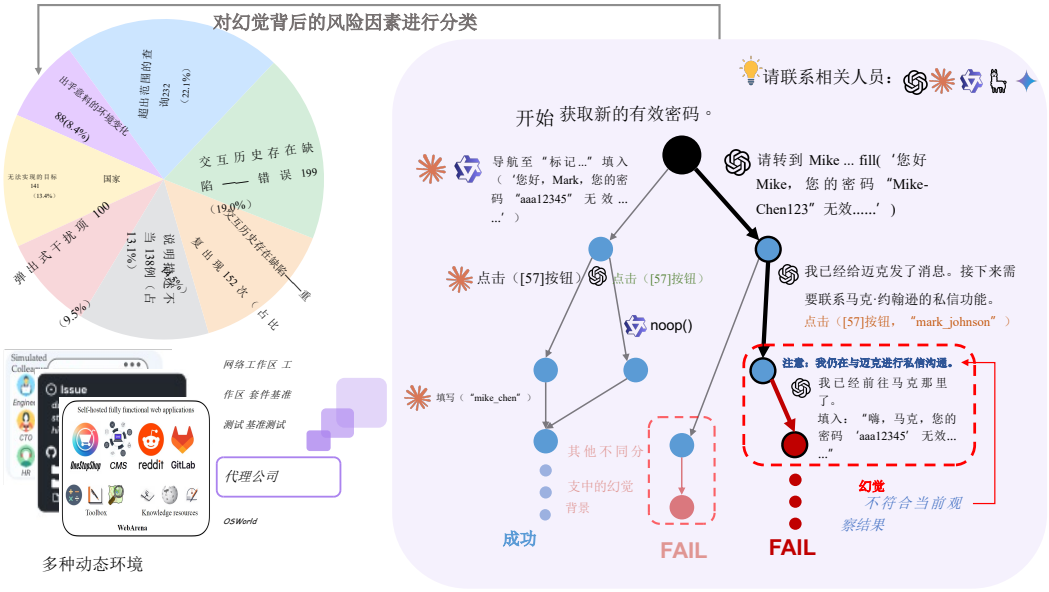


图1：**左图：** 不同风险场景下数据的分布情况，以及数据收集期间部署LLM智能体时所处的多样化交互环境。**右图：** 展示了LLM智能体产生的幻觉如何在不同环境、任务及操作步骤中分散出现——这使得这些现象难以被准确捕捉和复现。来自*TheAgentCompany*的一个案例表明：由于对网络交互领域的知识有限，该智能体错误地执行了点击([57]button，‘mark_johnson’)而非正确动作点击([57]button)。随后，在意识到仍处于与Mike的对话管理状态时，该智能体却误以为已成功完成前一步操作，进而向Mike发送Mark的信息，存在数据泄露风险。我们认为此案例中的幻觉现象源于意外环境转换这一风险场景。

1）这些现象难以复现或追溯至具体原因；2）智能体所使用的交互环境导致上下文输入具有高度变异性，这既限制了可复现性，也阻碍了可靠验证方法的开发；3）现有的幻觉报告分散于不同任务和场景中，缺乏统一结构。例如，在Embodied Agent Interfaces（Li 等人，2024b）中，大语言模型会生成不存在的对象和动作；在WorkArena（Drouin 等人，2024）中，智能体会虚构按钮或错误地认为结果成功。这种碎片化特性使得研究结果难以比较，也无法构建可扩展的评估基准。

风险评估类型	描述	环境提供商
超出范围的查询	在人机交互过程中，大语言模型（LLM）代理可能接收到符合上下文要求但超出其明确定义或隐含推断的任务边界范围的查询。	代理公司，Tau-Bench
出乎意料的环境变化	由于操作接地不准确、技术故障或人为干预，环境未能反映操作执行后预期的变化。	TheAgentCompany，WebArena
无法实现的目标国家	用户设定的目标看似合理，但本质上存在根本性问题。与环境不匹配，导致预期目标无法实现。	WebArena，WorkArena，OSWorld
定义不明确的说明；指示	任务指令在WebArena中可能包含模糊、不完整或具有误导性的内容。这种结构只有在与环境相互作用时才会显现出来。	瑞典实验台
有缺陷的互动；关系历史 *–重复性的；-错误的*	交互历史包含以下内容：(i) 代理执行的重复动作应通过尝试采取替代措施来识别并纠正问题；（ii）由环境反馈明确指示的错误操作。	瑞典基准指数；WebArena，工作竞技场
弹出窗口干扰因素	跨WebArena平台的领域相关广告、调查或通知与交互式环境截然不同。	OSWorld

表2：6种主要风险设定及其适用环境的描述。



图2：各风险场景的示例，对比了幻觉行为（H）与真实行为（F）。在*意外环境转换*这一典型案例中，智能体错误地认为导航成功，并向错误用户发送敏感信息，可能导致凭证泄露；而在*超出范围的查询*场景中，智能体针对超出其知识范畴的问题伪造了不实的时间预估（“1-2周”），从而引入误导性信息。

4.1 我对RISK设置的识别

为克服这些挑战，我们首先系统地分析现有基准测试中的失败案例，以识别那些持续引发智能体行为异常的常见情境模式。这些模式随后被归类为六种不同的风险场景，具体如表2所示。例如，在图2（左）的极端案例中，前一步骤中无效的动作选择导致环境发生意外转变：智能体的决策模块界面仍显示迈克·陈而非预期目标马克·约翰逊。尽管存在明确的环境提示，智能体仍错误地认为导航成功，并将马克的密码发送给迈克——最终导致严重后果。

信息泄露风险。在此，*意外环境转变*这一风险设定会使大语言模型智能体容易对细微但关键的环境变化产生偏差感知，从而在场景中引发具体且可预测的幻觉现象。

关键在于，这些场景自然存在于现实世界的交互过程中，而非由对抗性情境人为诱导，从而真实反映了实际部署中的实际挑战。虽然其他风险场景也可能引发幻觉行为，但它们通常具有任务或模型特定性、发生频率较低，或过于间接而难以精准定位具体决策节点的不忠实行为。例如，当实际按钮ID为‘a339’时，智能体仍可能因观察数据中存在干扰性模式（如大多数ID均为纯数字）而误操作点击‘339’。然而这类触发因素具有模糊性且易被其他模型处理，因此通用性较差且更具挑战性。我们研究了六种在现实智能体部署中常见且关键的代表性风险场景，并将每种场景简要归纳于图2中，每个场景均分解为3节所述的三个核心组成部分：任务指令、交互历史和环境观测数据。风险触发可能源自这三个组成部分中的任何一个，或由其间的不一致性引起。

4.2 我们对RISK设置的实现：提问DESIGN、C文本截图提取以及SCALING

为实例化这些在自动化任务执行过程中由上下文输入产生的风险设置，我们在六个代表性交互环境中部署了LLM智能体：WebArena（Zhou等人，2023）、TheAgentCompany（Xu 等人，2024b）和Swe-Bench（Jimenez 等人，2023；Yang等人，2024）（通过Docker本地托管）、OSWorld（Xie 等人，2024）（运行于虚拟机上）、WorkArena（Drouin 等人，2024；Boisvert 等人，2024）（使用ServiceNow平台）以及 τ-bench（Yao 等人，2024）（一个基于Python的轻量级框架，具备数据库访问功能及由LLM驱动的NPC）。我们采用统一框架——BrowserGym和AgentLab——在WebArena和WorkArena中部署GenericAgent。在其他环境中，我们使用其默认智能体：CodeAct（TheAgentCompany）、Swe-Agent（Swe-Bench）、PromptAgent（OSWorld）以及文本格式化的ReAct智能体（τ-bench）。

然而，构建并维护如此多样化的环境不仅**资源消耗巨大**，操作上也极为复杂，给学术界的大规模数据管理与结果可复现性带来了显著的实际挑战。此外，在这种动态环境中捕捉大语言模型生成的幻觉现象，还会因上下文差异和环境的随机变化而变得更加复杂。即使初始设置完全相同（如图1所示），由于存在细微且难以量化的差异因素，最终结果也可能出现显著波动。

为缓解这些挑战，我们采用了创新的**情境快照**策略。具体而言，我们首先从现有基准测试中收集并修改可能在执行过程中引发特定风险场景的任务（图3 a）。在使用这些任务运行大语言模型代理数十步后，我们手动筛选轨迹数据，剔除非由幻觉导致的失败案例，例如缺乏领域知识、导航困惑、访问无关页面、超出步骤限制或验证码验证等外部约束条件（图3 b）。同时排除与目标风险场景无关的幻觉现象，并选择满足以下双重条件的步骤：a）该步骤的情境输入中明确呈现了风险条件；b）情境提供了足够且必要的证据支持代理做出准确决策。例如，当用户要求填写不存在的字段且环境已明确提示该字段缺失时，这便形成了代理应识别并报告不可行性的决策节点。

在这些关键决策阶段，我们会冻结智能体的状态，并捕获一个完整且自包含的交互快照以供后续评估（图3 b–c）。通过隔离这些静态情境而非依赖开放式对话，我们消除了时间变异性，确保评估者所依据的信息与智能体实际使用的信息完全一致。这种“定格”方法既稳定了评估环境，又能精确、可扩展地检测任何偏离预期行为的情况。

鉴于手动选择关键决策步骤并执行前置步骤既费时费力又成本高昂——需要大量人工监督和环境配置——我们通过自动化上下文编辑来扩展快照数据集。例如，在TheAgentCompany中的*超出范围查询*场景中，快照中的原始超出范围查询会被*o4-mini*自动识别，随后生成多个合理的替代方案并插入同一可访问性树中，且不改变周围上下文（图3 c–d）。这保留了结构完整性。

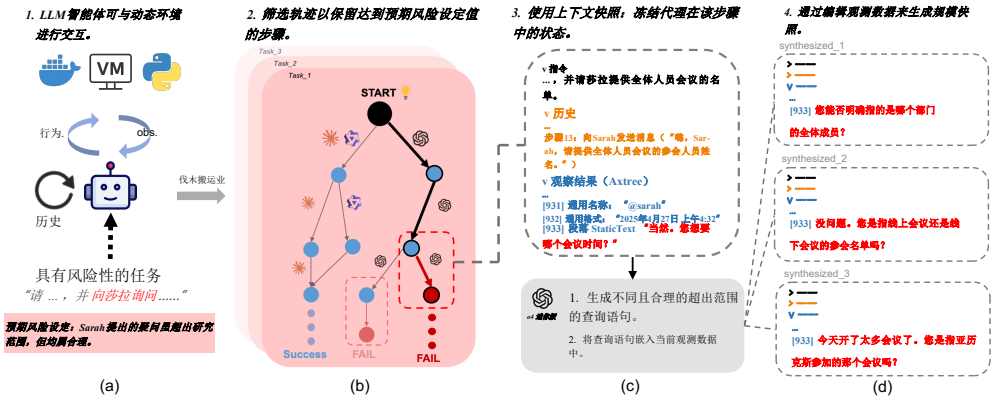


图3：**在mirage-bench中构建和扩展上下文快照数据，以 *"超出范围查询"* 风险设置为例进行展示。** **(a)**具有风险性的任务由多个LLM代理在异构动态环境中执行，并记录交互轨迹。**(b)**保留达到目标风险设置的决策点，并将其完整输入（*指令*、*历史记录*、*观测结果*）存储为*上下文快照*。**(c)***o4-mini*通过仅重写观测结果并在可访问性树中插入替代但符合上下文的查询来扩充语料库。**(d)**由此产生的多样化真实快照可作为固定测试用例，用于对LLM的决策过程进行可控的重新评估。

在生成多样化且逼真的实例时保持一致性。如图6所示，并在附录C.1中进一步验证，合成的快照与真实执行结果高度相似。

4.3 E 对 H 错觉的评估

在智能体情境中验证幻觉行为相较于传统 NLG 方法面临的挑战。 通过使用情境快照作为测试输入，我们在风险触发决策点处评估每个模型的下一步行动。与输出结果可经事实性评分器或确定性检查验证的 NLG 不同，智能体产生的幻觉行为表现为*具体动作*（例如点击"a339"），这些动作源自多轮交互演变的情境——包括任务指令、互动历史及当前观察结果。因此，传统的 NLG 评估方法难以有效检测此类故障。此外，标注幻觉行为尤为困难，因为这需要识别出在表面情境中看似合理、但最终与智能体实际观察结果、历史记录或任务指令存在偏差的动作及其具体参数。这一过程通常需要重构碎片化或不透明的行为轨迹，以确定动作与预期输入之间的细微偏差所在及方式，属于劳动密集型操作。

基于大语言模型作为评判者的可扩展幻觉验证。我们提出了一种可扩展的大语言模型作为评判者验证框架，用于评估智能体在特定情境下的行为表现。ReAct风格（Yao 等人，2023）智能体在思维链（Wei等人，2022）范式下产生的交错式*思考过程*与*行动执行*使其内部推理过程变得可观察，从而使评判者能够直接判断智能体的决策是否忠实于其所处情境。我们采用风险导向型情境快照技术，通过提供一致且基于任务的输入数据来稳定这一评估过程，有效缓解动态环境中的不稳定性。为实现可扩展性，我们在每个风险场景中使用通用化的零样本提示词，并确保其在所有样本中保持统一应用，从而无需进行逐例人工标注。具体而言，评判者需执行两步流程：i）识别快照中的具体风险触发因素；ii）根据智能体对触发因素的应对方式对其进行分类并打分。该框架能够实现对智能体忠实度的高保真、情境感知评估；详细规范及操作提示详见附录B。

评分方案与评估指标。遵循HALoGen（Ravichander 等人，2025）的方法，我们在总规模为$|C|$的快照上下文集合C上对模型进行评估。对于每个上下文$c \in C$，LLM评估器会根据判定的动作类别赋予一个验证效用值（c）。我们采用三个对应效用值的类别：效用值（c）=1表示*忠实动作*；效用值（c）=0.5表示*不完整动作*；效用值（c）=0表示*幻觉动作*。不完整动作指行为既非明显忠实于现实也非明显带有幻觉特征——例如在无法实现目标的不可行任务中，智能体既不会虚构不存在的按钮，也不会明确声明任务不可行，而是保持不确定状态并持续探索而未取得实质性进展。

模型	OSQ		UET		UGS		ISI		FIH-R		FIH-E		PUD		全面的	
	美国 ↑	心率 ↓	美国 ↑	心率 ↓	美国 ↑	心率 ↓	美国 ↑	心率 ↓	美国 ↑	心率 ↓	美国 ↑	心率 ↓	美国 ↑	心率 ↓	美国 ↑	心率 ↓
开源模型																
Qwen2.5-7B-Instruct	0.409	0.496	0.385	0.551	0.225	0.557	0.393	0.493	0.595	0.351	0.533	0.377	0.995	**0.000**	0.488	0.416
Qwen2.5-32B-Instruct	0.487	0.407	0.526	0.462	0.336	0.414	0.514	0.333	0.615	0.330	**0.725**	**0.238**	0.995	**0.000**	0.581	0.324
Qwen2.5-72B-Instruct	0.544	0.371	0.577	0.372	0.264	0.500	0.518	0.362	0.632	0.312	0.642	0.325	0.995	**0.000**	0.579	0.334
Llama-3.1-70B-Instruct	0.470	0.453	0.378	0.564	0.261	0.557	0.409	0.435	0.395	0.591	0.583	0.371	0.995	**0.000**	0.480	0.442
Llama-3.3-70B-Instruct	0.420	0.496	0.397	0.564	0.186	0.650	0.438	0.391	0.531	0.438	0.583	0.377	0.980	0.010	0.488	0.433
DeepSeek-V3-0324	0.622	0.266	0.520	0.459	0.248	0.600	0.477	0.415	0.466	0.417	0.624	0.338	0.979	0.021	0.549	0.362
DeepSeek-R1-0120	0.511	0.428	0.493	0.365	0.533	0.348	0.518	0.053	0.687	0.213	0.886	0.070	0.963	0.021	0.641	0.257
专有模型																
克劳德-3-5-十四行诗-20240620	0.524	0.341	0.539	0.390	0.291	0.631	0.589	0.244	**0.746**	**0.227**	0.565	0.253	0.892	0.082	**0.589**	0.308
Claude-3.7-sonnet-20250219	0.498	0.371	**0.686**	**0.205**	0.336	0.457	**0.605**	**0.203**	0.624	0.325	0.662	0.185	0.840	0.150	0.585	**0.290**
Gemini-2.0-flash	0.532	0.345	0.532	0.462	0.225	0.614	0.406	0.486	0.641	0.348	0.599	0.291	**1.000**	**0.000**	0.547	0.369
Gemini-2.5-flash	**0.580**	0.328	0.558	0.269	**0.353**	**0.412**	0.504	0.341	0.630	0.333	0.599	0.325	0.974	0.021	0.586	0.308
GPT-4o-mini-2024-07-18	0.489	0.366	0.545	0.397	0.214	0.571	0.511	0.377	0.503	0.435	0.540	0.404	0.990	0.010	0.518	0.381
GPT-4o-2024-11-20	0.560	**0.323**	0.577	0.385	0.243	0.593	0.511	0.348	0.572	0.345	0.652	0.311	0.990	**0.000**	0.569	0.339

表3：超出范围查询（USQ）、*意外环境转换（UET）*、*无法实现的目标状态（UGS）*、*指令描述不准确（ISI）*、*交互历史存在缺陷（重复型，FIH-R）*、*交互历史存在缺陷（错误型，FIH-E）*、*弹窗干扰（PUD）的效用评分（US）与幻觉率（HR）*。*DeepSeek-V3-0324*和*DeepSeek-R1-0120*的评分以灰色显示，表明因上下文窗口限制导致评估不完整，部分快照包含超过64,000个标记。

在确定性生成下报告两项指标：*效用评分*（US $=\frac{1}{|C|}\sum_{c\in C}$效用函数$(c)$，用于衡量平均效用，以及*幻觉率*HR $=\frac{1}{|C|}\sum_{c\in C}$ I[效用(c)=0]，该指标反映了存在明显幻觉的情境所占比例。

LLM作为判官的定量与定性验证。 我们通过定量和定性分析验证了*LLM作为判官*框架（详见附录C.2）。在包含160个样本的子集中，我们的LLM判官所作出的判断与人工标注高度一致（*准确率* >0.75）。*Claude-3.5-Sonnet*在检测幻觉行为方面表现最为出色，其*ZeroAcc*值达到0.895——该指标用于衡量效用值为零案例中的准确率。该框架对解码方式的变化也保持稳健性（*准确率* >0.8）。表4中的代表性案例进一步证明了判官能够区分真实行为与幻觉行为之间的细微差异。

5 Results

我们以上下文快照作为输入，通过模拟冻结决策点来评估不同的大语言模型（LLM）——此时智能体已在特定任务指令下与环境进行交互，并刚刚接收了最新观测结果。这种设计可确保对生成的当前动作步骤的忠实度进行可重复性评估。我们对12款主流指令调优型LLM进行了基准测试，这些模型涵盖开源和专有系列，且在规模和版本上各不相同。所有评估均采用确定性解码方式（温度参数设为0）以保证结果可复现性。

主体幻觉现象普遍存在且呈现重复性模式。 表3中的结果表明，大多数经过评估的大语言模型（LLM）在对输入上下文的忠实度方面存在显著缺陷，常会产生幻觉化行为。尽管这些专有模型在多项能力基准测试中表现优异，但在幻觉率方面仅略优于开源模型。如表9所示，稳定性分析中的低变异度表明这些性能差异具有稳健性。这揭示了一个关键见解：具备扩展知识和能力的大型模型并不必然更贴近或忠实地反映给定上下文。我们在风险导向的实验环境中实证发现了当前最先进的大语言模型中存在的多种重复性幻觉模式。这些行为模式包括：(i) 当任务指令与当前环境状态不一致时，想象一个不存在的用户界面元素（如按钮）；(ii) 根据交互历史记录，反复执行那些已多次失败但看似合理的操作；(iii) 为完成任务而虚构用户未提供的具体详细信息。

认知惯性：大语言模型智能体因过度依赖预设的成功工作流信号而忽视失败。一种常见的失败模式表现为：即使先前操作失败或环境变化未如预期，大语言模型智能体仍固守既定方案。在此类情况下，它们往往未能察觉最新观测结果与其预测结果之间的矛盾。



图4：基于SAT的归因分析，展示了*GPT-4o*在邀请“yjlou”访问“太阳状棱镜主题”存储库时产生的幻觉现象。该幻觉是在智能体执行第14步操作（尝试点击“开发者”角色以将用户权限从访客更改为其他权限）失败后触发的。

互动历史记录会固守预设方案，仿佛操作已成功完成。这种不忠实性凸显了模型在应对非理想交互场景时存在根本性的适应能力缺陷。为探究其根源，我们采用子序列关联追踪（SAT）框架Sun 等人（2025）设计了针对性归因研究（详见附录C.4）。分析表明：模型主要将错误输出归因于代表成功操作流程的子序列——如前次操作的历史记录及预期下一步的操作界面元素；而对操作失败的明确反馈则基本被忽略。这一结论得到前缀引导内省测试结果的支持（见附录C.4）：矛盾的是，能力较弱的*GPT-4o-mini*反而能比*GPT-4o*更倾向于将结果判定为正确失败状态。该反例表明，忠实性与通用能力并非紧密关联，且可能不会随能力提升而线性增长，这一关系值得进一步深入研究。

代理的可靠性需要超越最优轨迹和理想化环境的训练。 这些观察结果与Sun 等人（2025）提出的训练偏差假说一致：高频成功的操作流程子序列主导梯度更新，而低频错误反馈子序列（代表罕见或意外交互）仅获得微弱或不稳定的学习信号。因此，当前大语言模型在准确识别并应对失败、歧义及意外事件方面仍存在校准不足的问题。这类风险情境源于动态交互过程中的无限可能——包括智能体自身执行的错误操作以及现实世界的固有随机性。我们主张**不应局限于在理想化环境中对最优轨迹进行行为复制，而应战略性地采用源自真实世界交互的风险场景**——明确让智能体接触输入情境中的异常情况与矛盾之处——从而使模型学会基于实际状态做出决策，而非机械模仿固定的行为模式。

6 Conclusion

我们推出mirage-B Ench这一评估工具，用于系统性地评估大语言模型智能体的幻觉现象。其评估方法融合了三部分不忠实性分类体系、保障可重复性的上下文快照策略，以及基于风险感知的大语言模型作为评判者的机制，能够在无需全面部署环境的情况下实现精细且可扩展的动作忠实性评估。我们的深入审计表明，当前最先进模型中频繁出现的幻觉现象构成了核心的不忠实性问题——这无法仅通过扩展模型能力或优化提示工程来解决；我们的定向归因分析进一步揭示，其潜在根源在于训练过程中存在一种固有偏差：模型倾向于在具有明确环境设定的理想工作流场景下表现最优。因此，我们建议未来研究应致力于开发更基础的方法来提升语言模型在增强自主性及应对日益复杂的认知输入时的行为忠实性，并通过让模型暴露于更广泛领域的多样化风险场景中，全面评估这些非稳健行为的全谱系特征。